

PROYECTO SISTEMAS BASADOS EN CONICIMIENTO

Proyecto del segundo bimestre

Nombre: Carlos Xavier Hidalgo Paredes Fecha: 22/07/2021

Dominio de trabajo:

Artículos científicos sobre Mobile Device Security

Almacenamiento de datos RDF

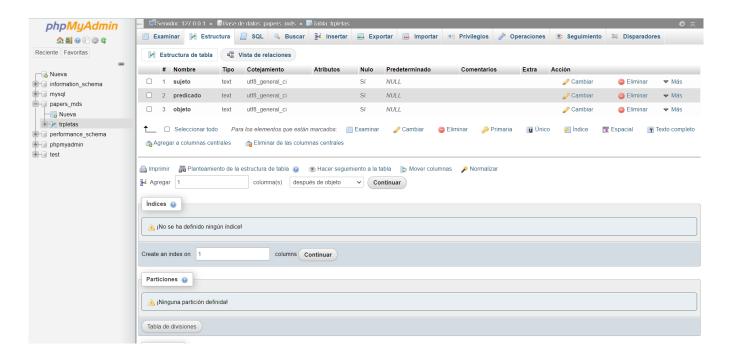
La *primera base de datos* utilizada para el almacenamiento de los datos pre-procesados es *MySql* asi mismo para guardar los datos ya procesados (tripletas)

La tabla para almacenar los datos *pre-procesados* queda de la siguiente manera:

Ш	TITULO	ABSTRACT	URL DOC	FECHA	NUM PAG	LEN	CITAS	NUM CITAS	AUTOR	TIPO	SOCIO	URL

La tabla para almacenar los datos ya *procesados* (tripletas) queda de la siguiente manera:

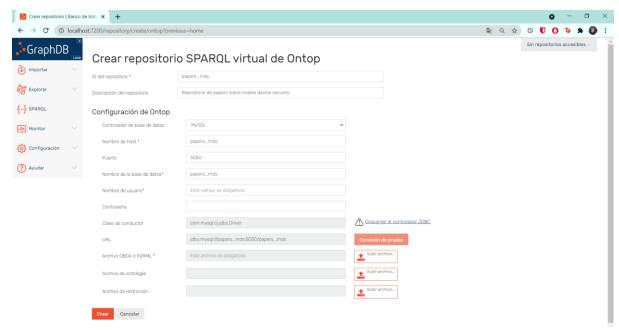
Sujeto	Predicado	Objeto



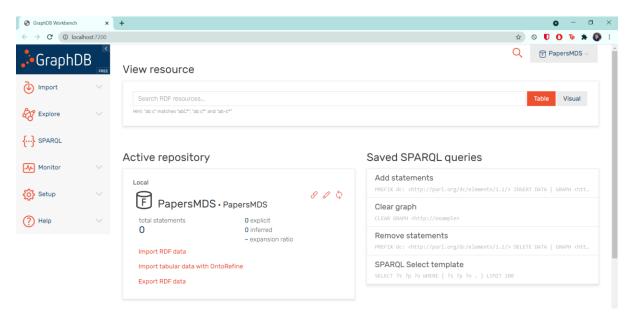
La **segunda base de datos** es GraphDB, es un repositorio que nos permite cargar datos, nos permite generar los grafos y realizar las consultas en Sparql por lo cual este repositorio



cumple con las especificaciones RDF y SPARQL, como adicional permite también la publicación de datos a la web.



El siguiente paso fue crear la base de datos denominada "PapersMDS", se almacenara las 40.383 tripletas generadas a través de la aplicación Jena, el repositorio permite importar Data RDF, data OntoRefine, permitiendo importar archivos .ttl, .ttls, .rdf, .rj, .n3, .nq, .trig, .trigs, .owl, .jsonld. En este caso las tripletas están transformadas en "N3-Triplet" el archivo a importar es en .csv



Ejemplo tripletas

De esta manera podemos ver detenidamente como se forman las tripletas, con el código ya implementado con los recursos, propiedades.

http://purl.org/ontology/bibo/uri>"https://dl.acm.org/doi/abs/10.1145/3386901.3389023"."



http://purl.org/dc/terms/title "SelMon reinforcing mobile device security with self-protected trust anchor." .

http://purl.org/ontology/bibo/numPages">"13".

http://www.w3.org/1999/02/22-rdf-syntax-ns#type

http://purl.org/ontology/bibo/Document.

http://purl.org/ontology/bibo/identifier "Paper1".

http://purl.org/dc/terms/date "June-2020" .

<http://proyecto.org/sbc/data/Paper1> <http://purl.org/dc/terms/format> "HTML" .

http://purl.org/sbc/data/Paper1>http://purl.org/sbc

http://purl.org/dc/terms/language">"en".

http://purl.org/ontology/bibo/abstract "Higher privileged trust anchors such as thin hypervisors and TrustZone have been adopted to protect mobile OSs. For instance the Samsung Knox security platform implements a kernel integrity monitor based on a hardware assisted virtualization technique for 64-bit."

http://xmlns.com/foaf/0.1/homepage>"https://dl.acm.org".

http://xmlns.com/foaf/0.1/name "acm" .

"http://purl.org/ontology/bibo/Publisher/Paper1" ..

><a href="http://purl.org/dc/terms/publisher<a href="http://purl.org/dc/terms/publisher<a href="http://purl.org/dc/terms/publisher<a href="http://publisher<a href="http://publisher</a

http://proyecto.org/sbc/data/BB Kang> http://vivoweb.org/ontology/rank "2" .

http://xmlns.com/foaf/0.1/name>"BB_Kang".

http://purl.org/dc/terms/creator http://vivoweb.org/ontology/Document/Paper1.

http://proyecto.org/sbc/data/BB_Kang

http://www.w3.org/1999/02/22-rdf-syntax-ns#type

http://xmlns.com/foaf/0.1/Person.

http://purl.org/spar/c4o/hasGlobalCountValue">| 5".

<http://proyecto.org/sbc/data/Paper1/26-June-2021/> <http://purl.org/spar/c4o/hasGlobalCountDate> "26-June-2021" .

http://proyecto.org/sbc/data/Paper1/26-June-2021/>

http://purl.org/spar/c4o/hasGlobalCitationFrequency

"http://purl.org/spar/c4o/GlobalCitationCount".

http://proyecto.org/sbc/data/Paper1/26-June-2021/>

http://www.w3.org/1999/02/22-rdf-syntax-ns#type

http://purl.org/spar/c4o/GlobalCitationCount.

http://proyecto.org/sbc/data/J_Jang http://vivoweb.org/ontology/rank "1" .

http://xmlns.com/foaf/0.1/name "J_Jang" .

<http://proyecto.org/sbc/data/J_Jang> <http://purl.org/dc/terms/creator> <http://purl.org/ontology/bibo/Document/Paper1> .

<http://proyecto.org/sbc/data/J_Jang><http://www.w3.org/1999/02/22-rdf-syntax-ns#type><http://xmlns.com/foaf/0.1/Person>.

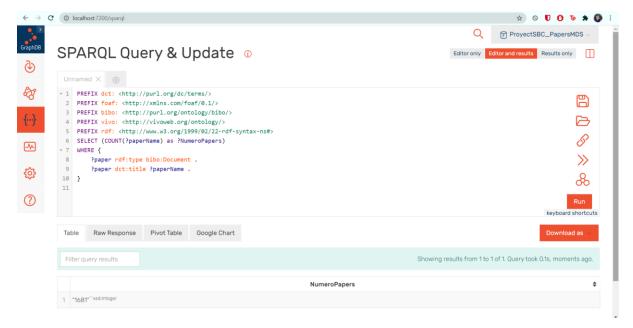
Este es un ejemplo claro de un paper transformado a "N-Triple", una vez trabajada con toda la data extraída de los diferentes recursos, se ha logrado obtener 40.383 tripletas, con la aplicación la una vez transformadas a tripletas, todas las almacenamos en un archivo csv, para luego ser exportado al repositorio denominado "PapersMDS", una vez exportado toda la información se podrá utilizar el repositorio con las tripletas realizando consultas en el lenguaje sparal.

Consultas SPARQL

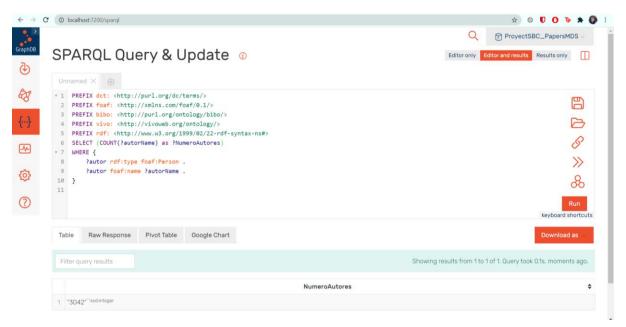
Implementar al menos 6 consultas SPARQL que ilustren el valor de los datos enlazados. Las consultas deberán aprovechar algunas de las ventajas de sparql para explorar grafos (como las properties paths). Además, realizando consultas SPARQI presentar un resumen de los datos (cuántos papers, cuántos autores, etc.)

1. Cuantos papers existen en el grafo?



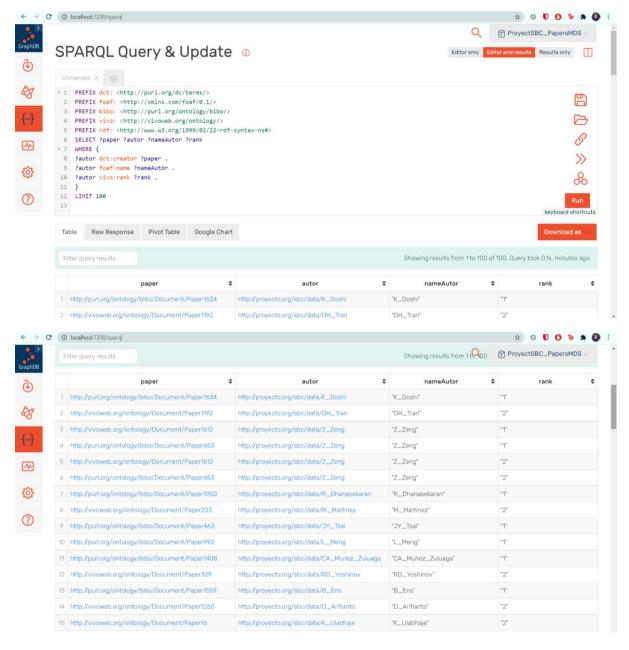


2. Cuantos autores existen en el grafo?



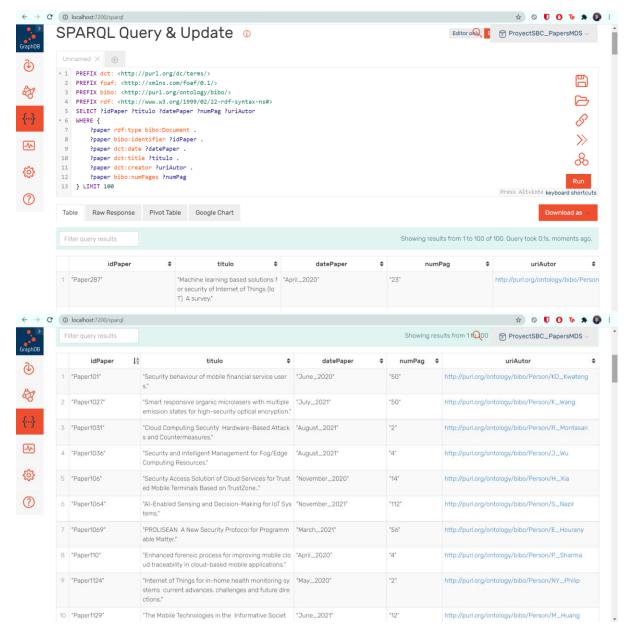
3. Cuál es el ranking que ocupan los autores en los papers?





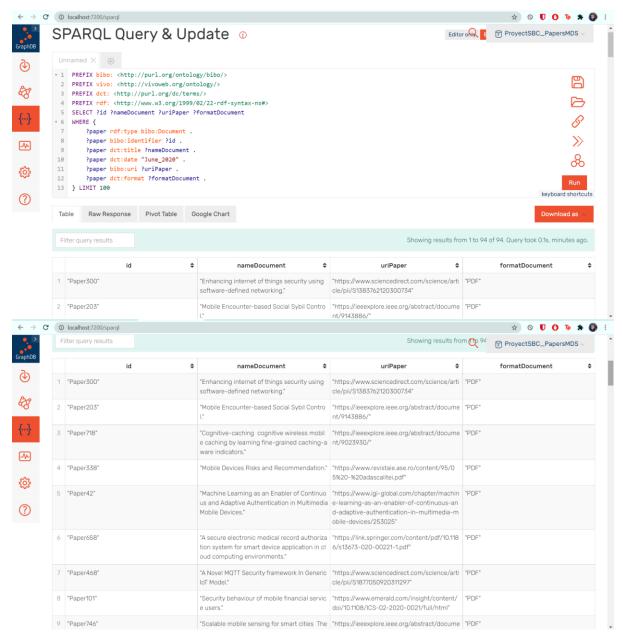
4. Cuáles son los Identificadores de los papers, adicionando la fecha de publicación, titulo, número de páginas y autor





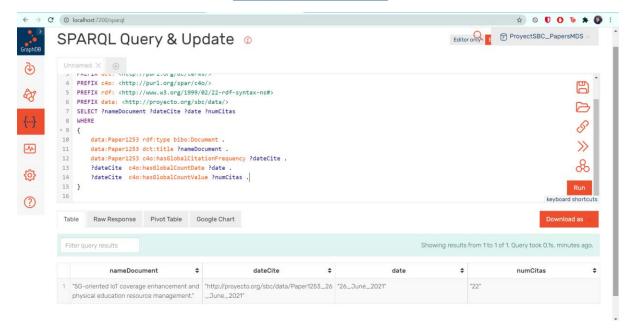
5. Se desea saber los datos principales de los papers, que fueron publicados en el mes de Junio del 2020





6. Cuantas veces fue citado el Paper15?





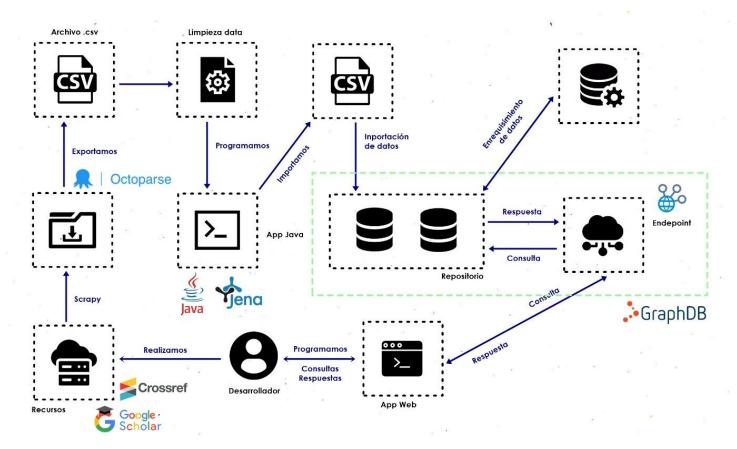
Implementación de la aplicación

Implementar la aplicación (buscador, sistema QA, etc.) que definieron en el primer bimestre. Describir el framework base utilizado (ElasticSearch, Haystack, etc.), además describir la arquitectura o pipeline diseñado, las configuraciones realizadas, componentes y lógica de implementación.

Funcionamiento de la aplicación

Ilustración de la transformación de los datos paso a paso, limpieza de datos, luego llegamos a la programación de la app para la transformación de las tripletas y en Java – Jena, una ves tenida toda la información enriquesimos los datos que tenemos y procedemos a subir a nuestro repositorio GraphDB para poder utilizar el endpoint del mismo y asi podenos conectar mediante la App Web que se desarrolló en Html5, css3, JavaScript, la cual contiene la información y formularios de búsqueda.





Aplicación web

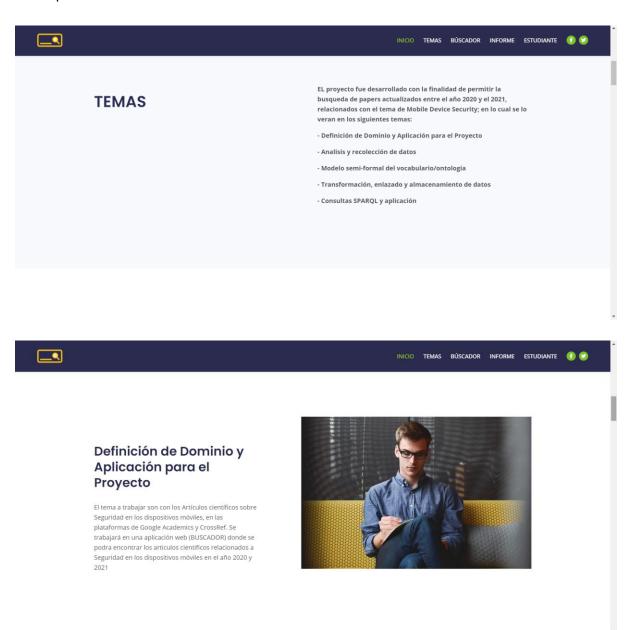
La página web esta trabajada con HTML5, CSS3, JavaScript, distribuida en diferentes secciones Pagina de inicio, temas, buscador, informe y estudiante.

Inicio: en la sección de inicio encontramos un fronted que permite visualizar el tema principal y un botón "Estudiante" donde lleva a un breve resumen del proyecto y la información del estudiante.





Temas: en esta sección se puede visualizar una breve introducción, con los temas que se trataron en la resolución del proyecto; asi mismo se puede encontrar la información correspondiente a cada tema.

















Analisis y recolección de datos

Los recursos de donde se extrajo la data es de Google Academic, Crossef, obteniendo datos como el título, resumen, fecha de publiación, número de páginas, autores, citas, tipo de documento, publishers, entre otros; la búsqueda se hará respecto al 2020 y 2021.

El método de extracción fue con scrapy a las páginas de Google Academic, Crossef y Scimago, utilizando Octoparse (Octopus Data); es una herramienta que permite realizar scrapy de forma masiva. Es una herramienta que permite extraer datos de una web, extracto de imágenes, resumen y publicación de datos sobre casi cualquier sitio web y te permitirá guardarlos como datos estructurados limpios en tu formato de



INICIO TEMAS BÚSCADOR INFORME ESTUDIANTE



Modelo semi-formal del vocabulario/ontología

Vocabulario:

Los vocabularios con los que se utilizaran para el proyecto son FOAF, BIBO, VIVO, C40, DCTerms, DCElements, DCOntology, estos nos permitira armar los prefijos, para despues poder generar las tripletas

Prefijos:

- PREFIX data: http://proyecto.org/sbc/data/
- PREFIX c4o: http://purl.org/spar/c4o/
- PREFIX dbo: http://dbpedia.org/ontology/
- PREFIX dct: http://purl.org/dc/terms/
- PREFIX dce: http://purl.org/dc/elements/ ■ PREFIX vivo: http://vivoweb.org/ontology/
- PREFIX bibo: http://purl.org/ontology/bibo/
- PREFIX foaf: http://xmlns.com/foaf/0.1/



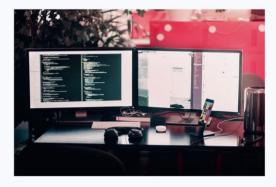






INICIO TEMAS BÚSCADOR INFORME ESTUDIANTE 🕧 🙄





Transformación, enlazado y almacenamiento de datos

La transformación de los datos se lo realizó mediante una aplicación en JAVA con Jena, esta app nos permitió crear los prefijos, recursos, modelos y añadir las propiedades; para finalmente crear las tripletas en RDF

El almacenamiento de los datos se lo realizara en un repositorio GrapDB, este nos permite cargar datos en diferentes formatos, permite generar los grafos y realizar las consultas en Sparql, lo cual este repositorio cumple con las especificaciones RDF y SPARQL para almacenar los datos RDF que generamos con la app Jena.



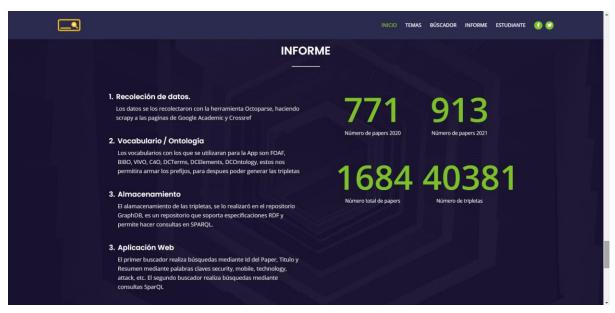


Buscador: en la sección del buscador encontraremos un pequeño formulario donde podemos realizar búsquedas mediante Id del proyecto, Titulo, Resumen usando palabras clave en estas últimas dos secciones, en la parte del medio información de la sección y en la parte del buscador Sparql, encontramos un área de texto donde podemos ingresar directamente una consulta en Sparql y se podrá obtener el resultado, debajo de todo se trabaja con un endpoint con GraphDB donde se encuentra almacenado la información con la que se trabajará.



Informe: en esta sección se puede visualizar en resumen el trabajo realizado y los datos obtenidos, e esta caso el número de papers en el año 2020, numero de papers en el 2021, numero de papers totales y finalmente el número de tripletas generadas en su totalidad por la App Jena.





Estudiante: se puede visualizar la presentación del estudiante y asi mismo un icono de GitHub donde lleva directamente al repositorio donde se encuentra el proyecto, se podrá ver entregables, aplicación, datos, informes, etc.

